

PHÂN CỤM GAME TRÊN STEAM BẰNG THUẬT TOÁN K-MEANS

Người thực hiện : Dương Quốc Huy

Giảng viên hướng dẫn : TS Nguyễn Văn Quyết





MỤC LỤC

- 1.Lí do chọn đề tài và mục tiêu
- 2.Dataset
- 3.Khám phá dữ liệu
- 4.Các mô hình training

Lý do chọn đề tài



- Tính thời sự và thực tiễn cao Ngành game đang phát triển mạnh tại Việt Nam và trên thế giới. Steam là nền tảng quen thuộc với cộng đồng game thủ, nên việc phân tích dữ liệu từ Steam có ý nghĩa thực tế, dễ liên hệ với đời sống.
- Phù hợp với nội dung môn học Môn Khai phá dữ liệu yêu cầu áp dụng các kỹ thuật như tiền xử lý dữ liệu, phân cụm (K-means, DBSCAN...), đánh giá mô hình (Silhouette Score, Elbow method). Đề tài này cho phép thực hành đầy đủ các bước: EDA, feature engineering, clustering, visualize và phân tích kết quả.
- Dữ liệu phong phú và dễ tiếp cận Dataset steam.csv (khoảng 27.000 game) có sẵn trên Kaggle, chứa nhiều đặc trưng đa dạng (numerical: price, ratings, playtime; categorical: genres, categories; text: steamspy_tags). Dữ liệu này lý tưởng để áp dụng các kỹ thuật clustering và trực quan hóa.
- Tiềm năng mở rộng Kết quả phân cụm có thể dùng làm nền tảng để phát triển thêm các mô hình khác như hệ thống gợi ý (collaborative filtering), phân loại game (classification), hoặc dự đoán thành công game (dựa trên ratings và owners).
- Sở thích cá nhân Bản thân em là người chơi game trên Steam và quan tâm đến việc hiểu tại sao một số game thành công lớn (như Dota 2, CS:GO) trong khi nhiều game khác ít người biết đến. Việc phân cụm giúp em khám phá sâu hơn về đặc điểm của các nhóm game này.

Mục tiêu của đề tài



Thu thập và tiền xử lý dữ liệu

- Làm sạch dataset steam.csv (xử lý giá trị thiếu, chuyển đổi định dạng cột owners, loại bỏ outlier nếu cần).
- Tạo các đặc trưng mới có ý nghĩa (ví dụ: tỷ lệ đánh giá tích cực, logarit thời gian chơi, one-hot encoding cho thể loại genres).
- Chuẩn hóa dữ liệu để phù hợp với các thuật toán phân cụm.

Khám phá dữ liệu (Exploratory Data Analysis – EDA)

- Phân tích phân bố của các đặc trưng chính (giá, đánh giá, thời gian chơi, số người sở hữu).
- Phát hiện outlier (game giá cao bất thường, game chơi cực lâu, game ít đánh giá).
- Phân tích tỷ lệ và sự phổ biến của các thể loại game (đặc biệt là Action, Indie, Casual, RPG...).

Áp dụng thuật toán phân cụm

- Sử dụng thuật toán K-means để phân nhóm các game.
- Xác định số lượng cụm tối ưu (sử dụng phương pháp Elbow và Silhouette Score cho K-means).

Đánh giá và trực quan hóa kết quả

- Đánh giá chất lượng cụm bằng các chỉ số nội tại (Silhouette Score, Davies-Bouldin Index).
- Trực quan hóa kết quả bằng biểu đồ scatter (sử dụng t-SNE hoặc PCA giảm chiều), biểu đồ cột so sánh đặc trưng giữa các cụm, và bảng tóm tắt.

Phân tích ý nghĩa kinh doanh và ứng dụng

- Mô tả đặc trưng nổi bật của từng cụm (ví dụ: cụm game free-to-play phổ biến, cụm game indie giá rẻ, cụm game AAA có thời gian chơi cao).
- Đề xuất ứng dụng thực tế: gợi ý game cho người chơi, hỗ trợ định giá sản phẩm, phân tích xu hướng thị trường game trên Steam.

LÝ DO CHỌN DATASET

TỔNG QUAN BỘ DỮ LIỆU

Nguồn gốc và thông tin chung

- Nguồn: Miễn phí trên Kaggle (Steam Store Games)
- Kích thước: 27.075 mẫu (tựa game).
- Số lượng đặc trưng gốc: 18 cột (features).
- Thời gian dữ liệu: Chủ yếu bao gồm các game phát hành đến khoảng năm 2019–2020 (dựa trên cột release_date).
- Định dạng: File CSV, dễ đọc và xử lý bằng pandas.

positive_ratings	negative_ratings	average_playtime	median_playtime	owners	price
124534	3339	17612	317	10000000-20000000	7.19
3318	633	277	62	5000000-10000000	3.99
3416	398	187	34	5000000-10000000	3.99
1273	267	258	184	5000000-10000000	3.99
5250	288	624	415	5000000-10000000	3.99

	appid	name	release_date	english	developer	publisher	platforms	required_age	categories	genres	steamspy_tags	achievements	positive_ratings	ne
0	10	Counter-Strike	2000-11-01	1	Valve	Valve	windows;mac;linux	0	Multi-player;Online Multi-Player;Local Multi-P...	Action	Action;FPS;Multiplayer	0	124534	
1	20	Team Fortress Classic	1999-04-01	1	Valve	Valve	windows;mac;linux	0	Multi-player;Online Multi-Player;Local Multi-P...	Action	Action;FPS;Multiplayer	0	3318	
2	30	Day of Defeat	2003-05-01	1	Valve	Valve	windows;mac;linux	0	Multi-player;Valve Anti-Cheat enabled	Action	FPS;World War II;Multiplayer	0	3416	
3	40	Deathmatch Classic	2001-06-01	1	Valve	Valve	windows;mac;linux	0	Multi-player;Online Multi-Player;Local Multi-P...	Action	Action;FPS;Multiplayer	0	1273	
4	50	Half-Life: Opposing Force	1999-11-01	1	Gearbox Software	Valve	windows;mac;linux	0	Single-player;Multi-player;Valve Anti-Cheat en...	Action	FPS;Action;Sci-fi	0	5250	

TỔNG QUAN BỘ DỮ LIỆU

Đặc điểm nổi bật

- Đa dạng loại dữ liệu: Kết hợp số (price, ratings, playtime), phân loại (genres, categories, platforms), văn bản (name, steamspy_tags), và khoảng (owners).
- Không có nhãn mục tiêu: Phù hợp hoàn hảo với bài toán phân cụm không giám sát (unsupervised clustering).
- Dữ liệu khá sạch: Ít missing values nghiêm trọng (chủ yếu ở một số cột không bắt buộc), dễ tiền xử lý.

Phân bố thực tế:

- Giá: Đa số game giá thấp ($<10\$$) hoặc free-to-play.
- Ratings: Nhiều game có tỷ lệ positive cao ($>70\%$).
- Playtime: Rất lệch (nhiều game gần 0, một số game hàng nghìn giờ).
- Owners: Nhiều game ở khoảng 20k–200k người sở hữu.
- Thể loại phổ biến: Action, Indie, Casual chiếm tỷ lệ lớn (Action $\sim 45\%$).

Lý do phù hợp với đề tài



- Cho phép thực hành đầy đủ quy trình khai phá dữ liệu: EDA, tiền xử lý (log transform, one-hot encoding, chuẩn hóa), phân cụm (K-means), đánh giá (Silhouette Score), trực quan hóa (t-SNE).
- Kết quả có ý nghĩa thực tiễn: Phân nhóm game để gợi ý, phân tích xu hướng Steam, hỗ trợ nhà phát triển định giá và chọn thể loại.

CHI TIẾT CÁC THUỘC TÍNH


STT	Tên cột	Kiểu dữ liệu	Mô tả sơ bộ
1	appid	Integer	ID duy nhất của game trên Steam
2	name	String	Tên game
3	release_date	Date/String	Ngày phát hành game
4	english	Integer (0/1)	Game có hỗ trợ tiếng Anh không (1: có)
5	developer	String	Nhà phát triển
6	publisher	String	Nhà phát hành
7	platforms	String	Nền tảng hỗ trợ (windows;mac;linux)
8	required_age	Integer	Độ tuổi yêu cầu (0, 16, 18...)
9	categories	String	Danh mục (Multi-player, Single-player, Steam Achievements...)
10	genres	String	Thể loại (Action;Indie;Casual;RPG;...)
11	steamspy_tags	String	Tag mô tả từ SteamSpy (FPS;Multiplayer;...)
12	achievements	Integer	Số lượng thành tựu
13	positive_ratings	Integer	Số đánh giá tích cực
14	negative_ratings	Integer	Số đánh giá tiêu cực
15	average_playtime	Integer	Thời gian chơi trung bình (phút)
16	median_playtime	Integer	Thời gian chơi trung vị (phút)
17	owners	String	Khoảng số người sở hữu (ví dụ: "10000000-20000000")
18	price	Float	Giá game (USD)

KHÁM PHÁ DỮ LIỆU


BIỂU ĐỒ PHÂN BỐ GAME THEO GIÁ



BIỂU ĐỒ PHÂN BỐ SỐ LƯỢNG GAME PHÁT HÀNH THEO NĂM



BOXPLOT THỜI GIAN CHƠI GAME TRUNG BÌNH



TIỀN XỬ LÝ DỮ LIỆU

Chuyển owners thành số trung bình

```
def owners_to_number(x):  
    if '-' in str(x):  
        low, high = str(x).split('-')  
        return (int(low.replace(',', '')) + int(high.replace(',', ''))) // 2  
    return 0
```

```
df['owners_num'] = df['owners'].apply(owners_to_number)
```

Tính tỷ lệ đánh giá tích cực

```
df['positive_ratio'] = df['positive_ratings'] / (df['positive_ratings'] + df['negative_ratings'] + 1e-6)
```

Fill missing values đơn giản

```
df.fillna({  
    'price': 0,  
    'positive_ratio': 0.5,  
    'log_playtime': 0,  
    'achievements': 0  
}, inplace=True)
```

Drop các hàng thiếu genres hoặc name (rất ít)

```
df.dropna(subset=['name', 'genres'], inplace=True)
```

```
print("Sau làm sạch:", df.shape)
```

KỸ THUẬT ĐẶC TRƯNG

```
X_input = df[['price', 'positive_ratio', 'average_playtime', 'achievements', 'owners_num']].copy()

X_input['log_price'] = np.log1p(X_input['price'])
X_input['log_playtime'] = np.log1p(X_input['average_playtime'])
X_input['log_owners'] = np.log1p(X_input['owners_num'])
X_input['log_achievements'] = np.log1p(X_input['achievements'])

# Loại bỏ cột gốc, chỉ giữ cột log và positive_ratio
features_to_use = ['log_price', 'log_playtime', 'log_owners', 'log_achievements', 'positive_ratio']
final_df = X_input[features_to_use]

# Thêm One-Hot Encoding cho Genres
popular_genres = ['Action', 'Indie', 'Casual', 'Adventure', 'Strategy', 'RPG', 'Simulation', 'Free to Play']
for genre in popular_genres:
    final_df.loc[:, genre] = df['genres'].str.contains(genre, case=False, na=False).astype(int)

scaler = StandardScaler()
X_scaled = scaler.fit_transform(final_df)

# PCA: Giữ lại 95% thông tin
pca = PCA(n_components=0.95)
X_pca = pca.fit_transform(X_scaled)

print(f"Dữ liệu gốc: {X_scaled.shape} -> Sau PCA: {X_pca.shape}")
```

MÔ HÌNH ÁP DỤNG

K-MEANS

K-Means là một thuật toán học không giám sát (Unsupervised Learning) dùng để phân cụm dữ liệu (clustering).


👉 Mục tiêu:

Chia dữ liệu thành K nhóm (K cụm) sao cho:

- Các điểm trong cùng một cụm thì giống nhau
- Các điểm khác cụm thì khác nhau

📌 Quan trọng:

- Không có nhãn sẵn (khác với classification)
- Máy tự tìm cấu trúc trong dữ liệu



Quy trình áp dụng

- Bước 1: Chọn số cụm K
- Bước 2: Khởi tạo centroids
- Bước 3: Gán điểm dữ liệu
- Bước 4: Cập nhật centroids
- Bước 5: Lặp cho đến khi không đổi

ƯU ĐIỂM

- K-Means dựa trên việc tính khoảng cách giữa các điểm dữ liệu và tâm cụm, nên rất trực quan và dễ triển khai.
- Thuật toán có độ phức tạp thấp, phù hợp với các tập dữ liệu lớn trong thực tế.
- K-Means được hỗ trợ sẵn trong nhiều thư viện học máy như Scikit-learn, giúp tiết kiệm thời gian phát triển.
- Khi các cụm có dạng hình cầu và phân bố tương đối đều, K-Means cho kết quả phân cụm tốt.
- Kết quả phân cụm có thể dễ dàng biểu diễn bằng biểu đồ 2D hoặc 3D để phân tích.

NHƯỢC ĐIỂM


- Việc chọn K không đơn giản và có thể ảnh hưởng lớn đến chất lượng kết quả phân cụm.
- Nếu chọn tâm cụm ban đầu không tốt, thuật toán có thể cho kết quả không tối ưu.
- K-Means không đảm bảo tìm được nghiệm tối ưu toàn cục cho bài toán phân cụm.
- Các điểm dữ liệu bất thường có thể làm lệch vị trí tâm cụm, dẫn đến phân cụm sai.
- K-Means hoạt động kém khi các cụm không có dạng hình cầu hoặc kích thước không đồng đều.

ELBOW

Elbow là phương pháp giúp xác định số cụm K phù hợp bằng cách quan sát mức độ giảm của tổng sai số trong cụm (WCSS – Within-Cluster Sum of Squares) khi tăng K.

Ý tưởng chính:

- ☞ Khi tăng K, WCSS sẽ giảm
- ☞ Đến một điểm nào đó, tốc độ giảm chậm lại rõ rệt
- ☞ Điểm đó tạo thành hình giống khuỷu tay (Elbow) → chọn K tại đó



WCSS (Within-Cluster Sum of Squares)

Dùng để:

- Chọn số cụm K (Elbow Method)

Ý nghĩa:

- Đo độ “chặt” của các cụm
- WCSS càng nhỏ $\rightarrow$ cụm càng tốt

Công thức:

$$WCSS = \sum_{i=1}^k \sum_{x \in C_i} ||x - \mu_i||^2$$

ƯU ĐIỂM

- Elbow dựa trên việc quan sát đồ thị WCSS theo số cụm K, nên rất trực quan và dễ áp dụng.
- Phương pháp này phù hợp với bài toán học không giám sát như K-Means.
- Elbow giúp người dùng có cơ sở hợp lý để lựa chọn K thay vì chọn ngẫu nhiên.
- Elbow thường được dùng trong các bài toán phân cụm và dễ giải thích trong thuyết trình.
- Phương pháp này hoạt động hiệu quả khi kết hợp trực tiếp với thuật toán K-Means.

NHƯỢC ĐIỂM

- Việc xác định “điểm khuỷu tay” phụ thuộc vào cách nhìn của người phân tích.
- Với một số tập dữ liệu, đồ thị WCSS giảm đều và khó xác định điểm gãy.
- Elbow chỉ mang tính gợi ý, không phải tiêu chí toán học chặt chẽ.
- Dữ liệu có nhiều hoặc phân bố phức tạp làm đồ thị Elbow khó phân tích.
- Elbow thường chỉ áp dụng hiệu quả cho K-Means và các biến thể tương tự.

Phương pháp đánh giá

Silhouette Score là chỉ số đánh giá nội tại trong bài toán phân cụm, dùng để đo:

- Mức độ chặt chẽ trong cùng cụm
- Mức độ tách biệt giữa các cụm


Chỉ số này không cần nhãn dữ liệu, rất phù hợp cho các thuật toán học không giám sát như K-Means.

Công thức:

$$s = \frac{b - a}{\max(a, b)}$$

- a: khoảng cách trung bình trong cùng cụm
- b: khoảng cách tới cụm gần nhất khác

Thang đo: [-1, 1]



K	Inertia (WCSS)	Silhouette Score
2	303,830	0.1865
3	279,346	0.1535
4	251,073	0.1551
5	232,986	0.1627
6	215,983	0.1421
7	205,480	0.1416
8	198,005	0.1322
9	190,257	0.1285
10	184,721	0.1301
11	180,453	0.1403

Phân cụm game

	Nhóm game (Cluster)	Đặc điểm chính	Chiến lược / Ý nghĩa thực tiễn
g	Cluster 0 (lớn nhất)	Game phổ biến, playtime cao, owners lớn, đánh giá tốt (thường Action/FPS/online)	Nhóm game "bom tấn" – nên ưu tiên gợi ý cho người chơi mới, giữ chân lâu dài
	Cluster 1	Game free-to-play hoặc chi phí thấp, playtime trung bình-cao, cộng đồng mạnh	Nhóm "nghiện" – tập trung khuyến mãi in-app, update thường xuyên
	Cluster 2	Game indie/casual, giá rẻ, đánh giá trung bình, playtime ngắn	Nhóm "thử nghiệm" – giảm giá thường xuyên, bundle để tăng lượt mua
	Cluster 3	Game niche hoặc cổ điển, giá trung bình-cao, đánh giá cao nhưng owners ít	Nhóm "chất lượng cao" – kích thích chi tiêu bằng nội dung đặc biệt

